

# Comprendre le Sharding dans MongoDB

Djebabla Ammar

Université de Technologie - Département Informatique

17 juin 2025

## Résumé

Ce document présente une explication approfondie du concept de **sharding** dans MongoDB, incluant son architecture, ses avantages et des cas d'utilisation pratiques. Un TP complet permet de mettre en œuvre ces concepts avec des exemples concrets de répartition de données.

## Table des matières

<b>1</b>	<b>Introduction au Sharding</b>	<b>2</b>
<b>2</b>	<b>Architecture détaillée</b>	<b>2</b>
2.1	Composants principaux . . . . .	2
2.2	Types de Sharding . . . . .	2
<b>3</b>	<b>Exemple détaillé : Sharding de 1000 clients</b>	<b>2</b>
3.1	Configuration initiale . . . . .	2
3.2	Découpage des données . . . . .	3
3.3	Insertion des données . . . . .	3
3.4	Vérification . . . . .	3
<b>4</b>	<b>TP : Répartition de données d'étudiants</b>	<b>4</b>
4.1	Objectifs pédagogiques . . . . .	4
4.2	Énoncé de l'exercice . . . . .	4
4.2.1	Partie 1 : Configuration initiale . . . . .	4
4.2.2	Partie 2 : Insertion des données . . . . .	4
4.2.3	Partie 3 : Analyse de la distribution . . . . .	5
<b>A</b>	<b>Annexe : Commandes utiles à connaître</b>	<b>5</b>

# 1 Introduction au Sharding

Le **sharding** est une technique fondamentale dans les bases de données distribuées qui permet de partitionner horizontalement les données sur plusieurs serveurs (appelés **shards**). Cette approche est particulièrement utile pour gérer de très grandes collections de données qui dépassent les capacités d'un seul serveur.

Architecture typique d'un cluster MongoDB shardé

## 2 Architecture détaillée

### 2.1 Composants principaux

- **mongos** : Le routeur qui dirige les opérations de lecture/écriture vers les shards appropriés
- **Config Servers** : Stockent les métadonnées du cluster (namespace, plages de clés, etc.)
- **Shards** : Serveurs contenant les données partitionnées

### 2.2 Types de Sharding

1. **Sharding par plage (Range-based)** : Partitionnement basé sur des plages de valeurs
2. **Sharding par hachage (Hash-based)** : Utilisation d'une fonction de hachage pour distribuer les données
3. **Sharding par zone (Zone-based)** : Attribution de plages spécifiques à des shards particuliers

## 3 Exemple détaillé : Sharding de 1000 clients

### 3.1 Configuration initiale

```
1 // Activer le sharding pour la base de données
2 use admin
3 sh.enableSharding("testdb")
4
5 // Créer la collection shardée
6 use testdb
7 db.createCollection("clients")
8
9 // Choisir la clé de sharding
10 sh.shardCollection("testdb.clients", { client_id: 1 })
```

Listing 1 – Initialisation du sharding

**Information**

**Remarque :** Le choix de la clé de sharding est crucial. Une bonne clé doit avoir :

- Une cardinalité élevée
- Une distribution uniforme
- Des requêtes qui l'utilisent fréquemment

## 3.2 Découpage des données

```
1 // Découper la plage de données en 3 chunks
2 sh.splitAt("testdb.clients", { client_id: 333 })
3 sh.splitAt("testdb.clients", { client_id: 666 })
4
5 // Répartir les chunks sur les shards
6 sh.moveChunk("testdb.clients",
7   { client_id: 100 }, "shard1")
8 sh.moveChunk("testdb.clients",
9   { client_id: 500 }, "shard2")
10 sh.moveChunk("testdb.clients",
11   { client_id: 800 }, "shard3")
```

Listing 2 – Découpage en chunks

## 3.3 Insertion des données

```
1 // Insertion de 1000 documents
2 for (let i = 1; i <= 1000; i++) {
3   db.clients.insertOne({
4     client_id: i,
5     nom: "Client_" + i,
6     email: "client" + i + "@example.com",
7     date_creation: new Date(),
8     solde: Math.random() * 1000
9   })
10 }
```

Listing 3 – Insertion des documents

## 3.4 Vérification

```
1 use config
2
3 // Afficher la distribution des chunks
4 db.chunks.aggregate([
```

```

5 { $match: { ns: "testdb.clients" }},
6 { $group: {
7   _id: "$shard",
8   count: { $sum: 1 },
9   min: { $min: "$min.client_id" },
10  max: { $max: "$max.client_id" }
11 }
12 }
13 ])
```

Listing 4 – Vérification de la distribution

TABLE 1 – Répartition des données

Shard	Nombre de chunks	Plage min	Plage max
shard1	1	1	332
shard2	1	333	665
shard3	1	666	1000

## 4 TP : Répartition de données d'étudiants

### 4.1 Objectifs pédagogiques

- Comprendre la répartition automatique des données
- Maîtriser les commandes de gestion du sharding
- Analyser la distribution des données

### 4.2 Énoncé de l'exercice

#### 4.2.1 Partie 1 : Configuration initiale

1. Créer une base de données nommée **etudiantsDB** et une collection **notes**.
2. Activer le sharding sur la base de données.
3. Activer le sharding sur la collection **notes** en utilisant **etudiant<sub>i</sub>dcommecldeshardingavecunhachage.V**

#### 4.2.2 Partie 2 : Insertion des données

4. Insérer 9000 documents dans la collection **notes**. Chaque document doit contenir :
  - un identifiant d'étudiant **etudiant<sub>i</sub>d**, *un nom sous la forme Etudiant\_X*,
  - deux notes aléatoires : **note\_math** et **note\_physique**,
  - une promotion calculée à partir de l'identifiant.

### 4.2.3 Partie 3 : Analyse de la distribution

1. Analyser la répartition des chunks entre les shards à l'aide d'une requête d'agrégation sur la base `config`.
2. Vérifier si le balancer est actif.

## Conclusion

Ce TP permet de manipuler les concepts clés du sharding :

- Configuration du sharding
- Insertion massive de données
- Analyse de la répartition et vérification de l'équilibrage

Pour approfondir le sujet, consulter la documentation officielle MongoDB : <https://www.mongodb.com/docs/manual/sharding/>

## A Annexe : Commandes utiles à connaître

- `sh.status()` : afficher l'état du sharding
- `sh.enableSharding("maDB")` : activer le sharding pour une base
- `sh.shardCollection("maDB.maCollection", { champ : "hashed" })` : activer le sharding sur une collection
- `sh.moveChunk()` : déplacer manuellement un chunk
- `sh.startBalancer()` / `sh.stopBalancer()` : activer/désactiver le balancer
- `db.collection.getShardDistribution()` : voir la répartition des documents